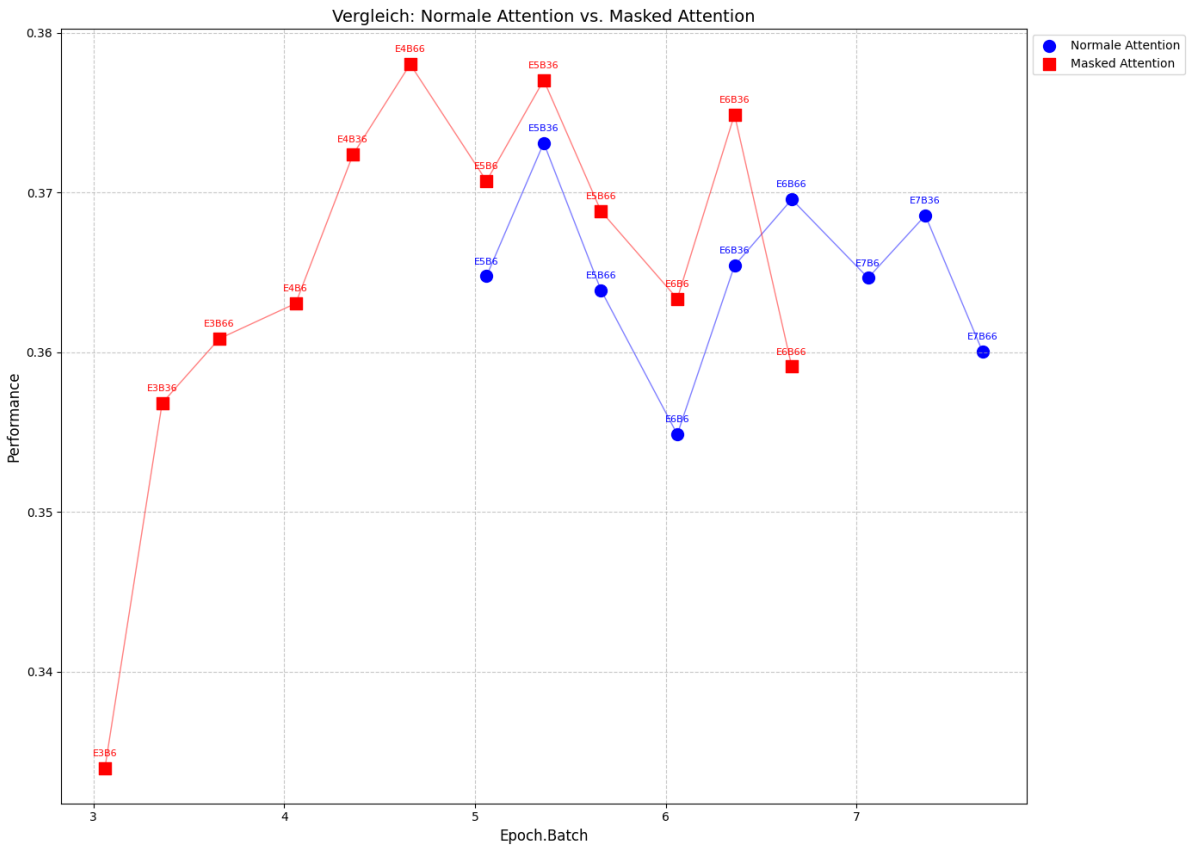
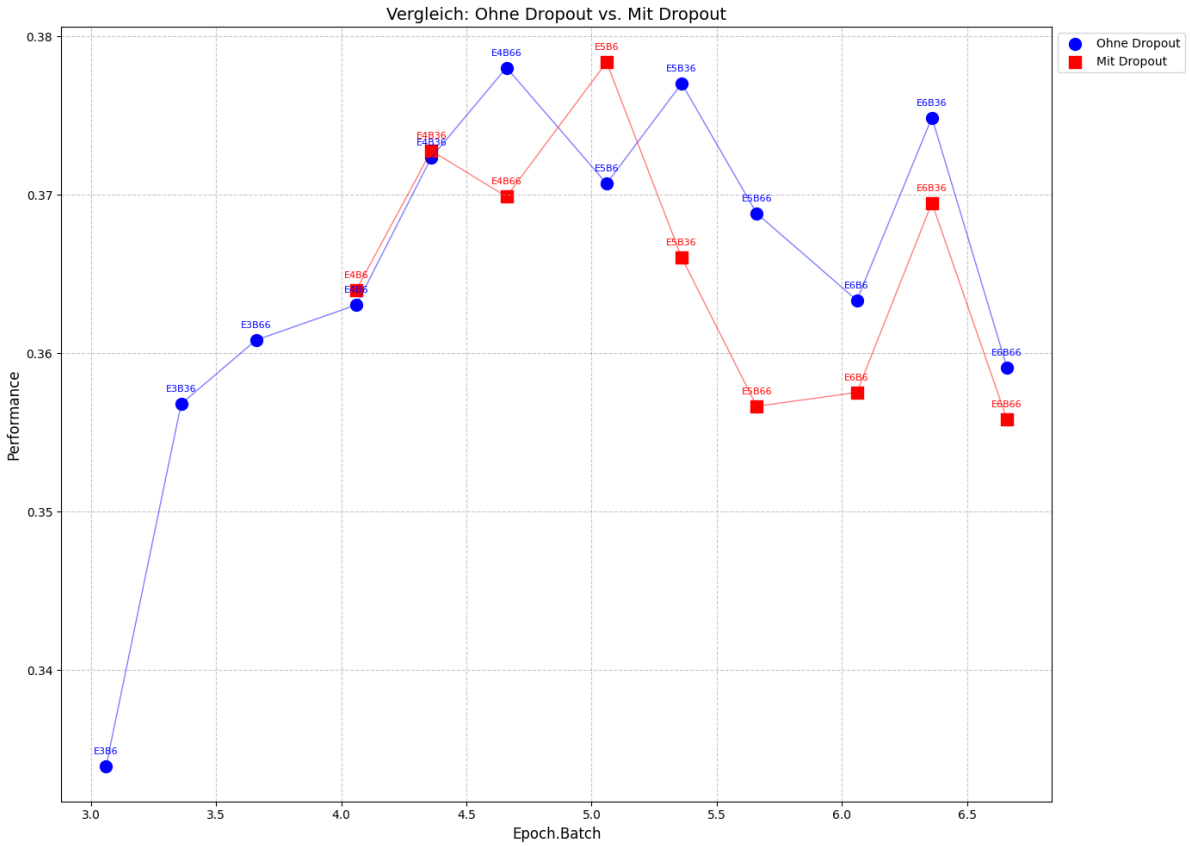
Dokumentation Versuch 6

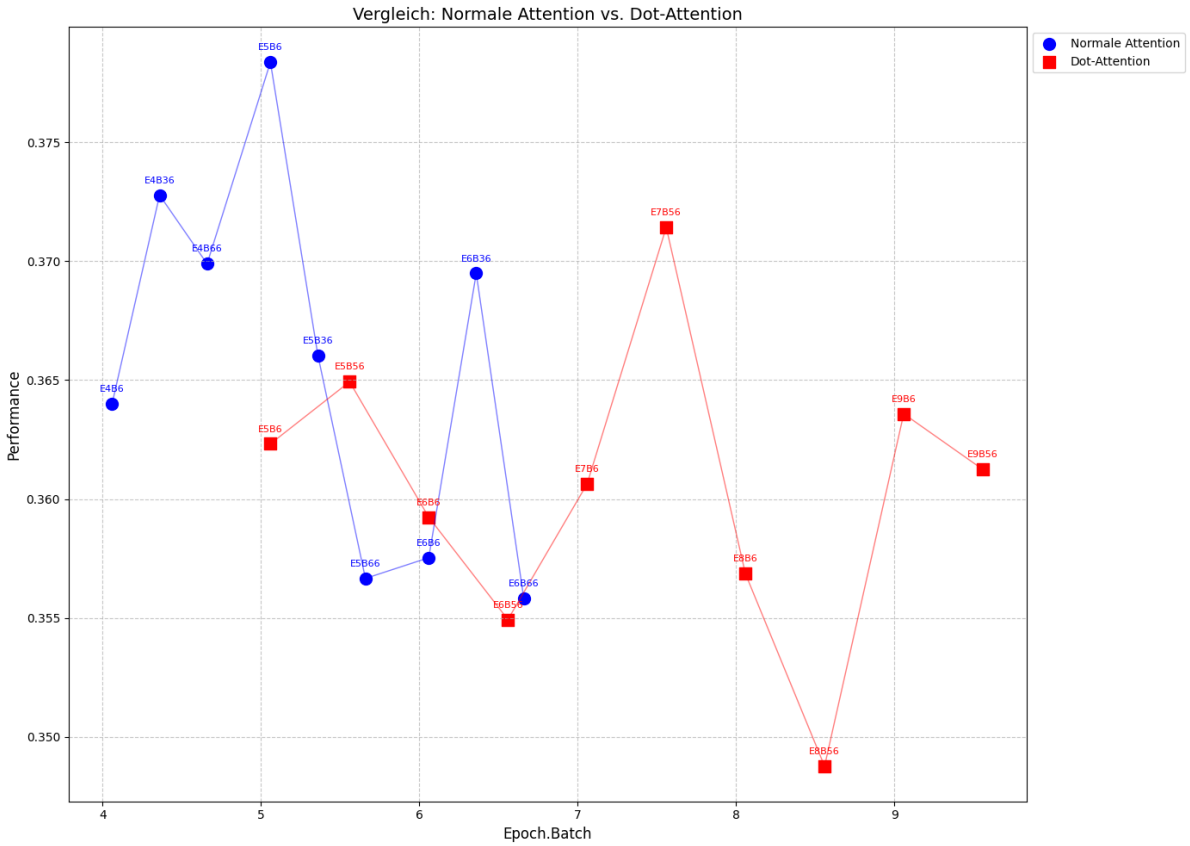
1. Problem/Verbesserung: Softmax über die falsche Dimension (Bleu 25 -> 35)
   In der Attention über die falsche Dimension die Wahrscheinlichkeitsverteilung berechnet. Wir haben nicht bedacht, dass der Tensor, als erste Dimension die Batch-Size hat. Somit mussten wir über die 3. Dimension Softmax machen.
2. Problem/Verbesserung: keine <s> am Anfang der Sätze.
   Motivation: Bei unseren Sätzen fehlten sehr häufig die ersten Wörter.
   Lösung: „<s>“ am Anfang der Sätze hinzugefügt. Nötig, damit der erste Decoder Step mit „<s>“ anfängt und nicht mit dem ersten Wort des Satzes.
3. Verbesserung: Attention-Masking
   Sowohl in den Source- als auch in den Target-Sequenzen, befinden sich (viele) Padding-Elemente, welche nicht in die Attention mit einberechnet werden sollten.
   Ergebnis: Man sieht, dass das lokale Maximum des Bleu-Wertes früher erreicht wird.



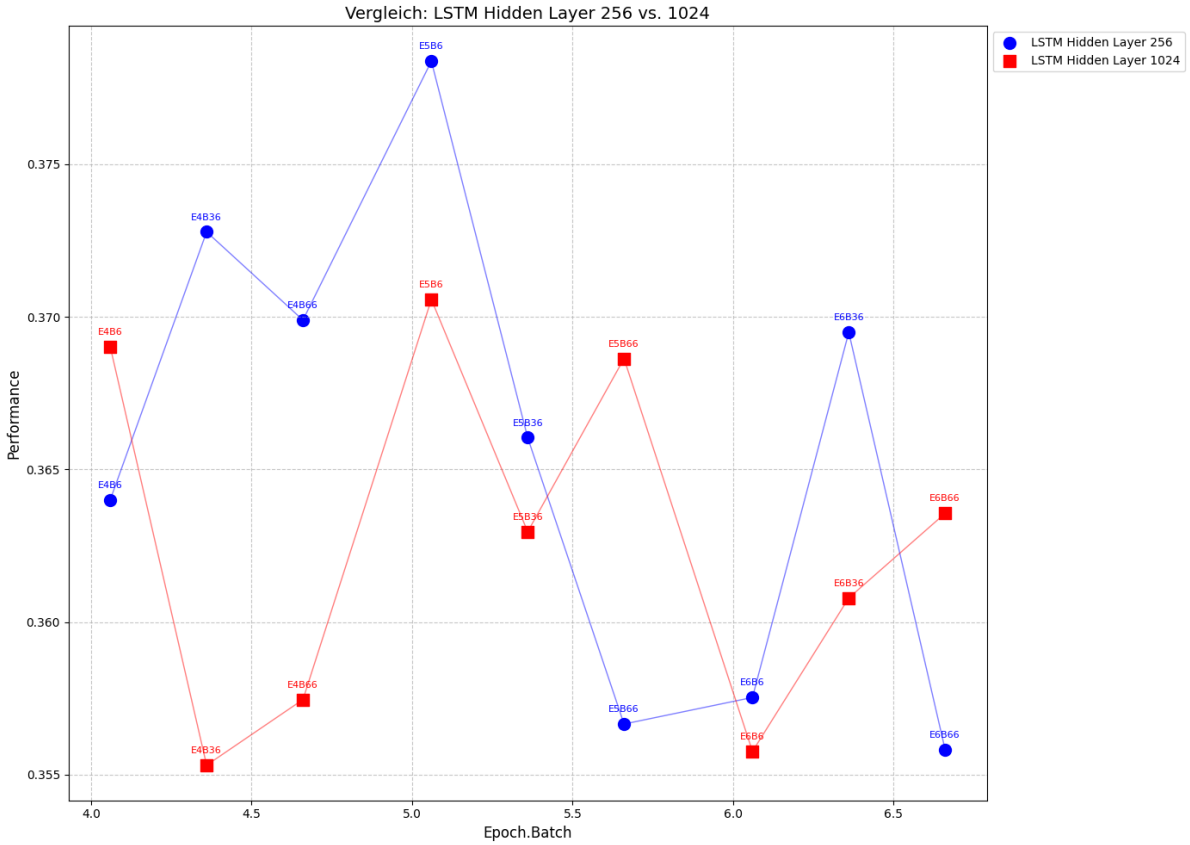
4. Verbesserung: Dropout
   Ergebnis:



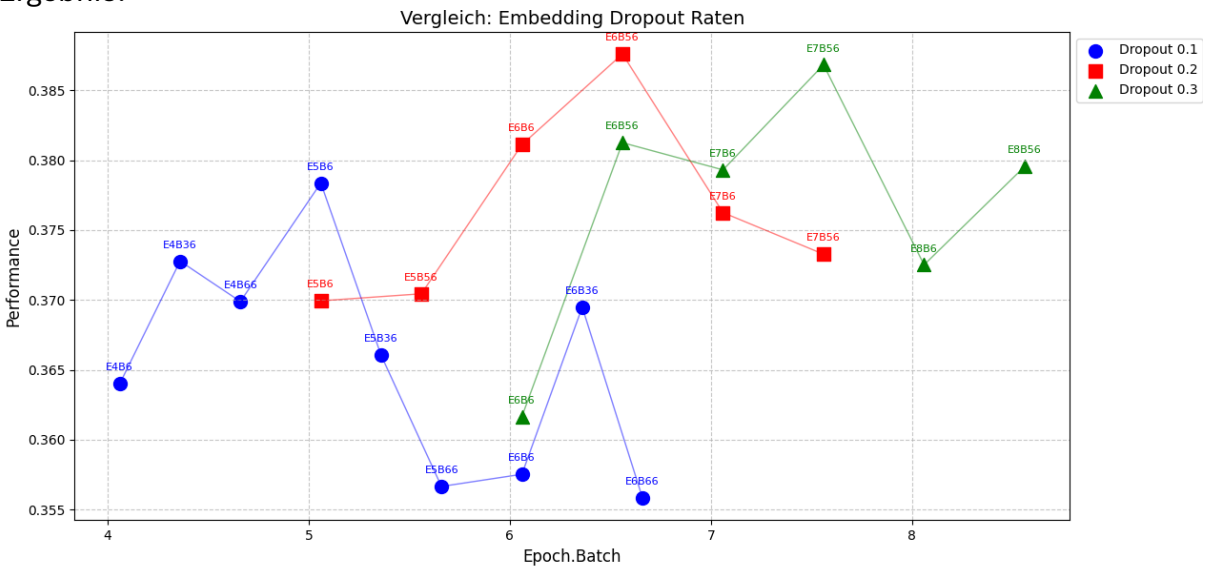
5. (versuchte) Verbesserung: Dot-Product Attention
   Ergebnis:



6. (versuchte) Verbesserung: Hidden-Sizes
   Ergebnis:



7. Dropout variiert
   Ergebnis:



---

8. Außerdem noch gemacht: Decoder Layer Size variiert